

EEG Motor İmgelem Sinyallerinin Derin Öğrenme Yöntemleriyle Sınıflandırılması: BCI Uygulamalarına Yönelik Bir Çalışma

Yazar Adı

Mayıs 2026

Özet

Bu çalışmada PhysioNet EEG Motor Movement/Imagery Database kullanılarak motor imgelem temelli beyin-bilgisayar arayüzü sınıflandırması ele alınmıştır. Sol ve sağ el görevlerini içeren EEG kayıtları standart ön işleme adımlarından geçirildikten sonra EEGNet, ShallowConvNet ve DeepConvNet mimarileri ile değerlendirilmiştir. Tüm deneyler denek içi beş katlı çapraz doğrulama düzeninde yürütülmüştür. Sonuçlar, küçük örneklemli EEG verilerinde EEGNet'in daha dengeli ve kararlı bir performans sunduğunu göstermiştir. Ayrıca, modellerden elde edilen gömleme vektörleri üzerinde PCA uygulanarak boyut azaltma yapılmış; buna karşın doğrusal sınıflandırma başarımında belirgin düşüş gözlenmiştir.

1 Giriş

Motor nöron hastalıkları, ileri evre Parkinson olguları ve inme sonrası gelişen ağır motor kayıplar, bireylerin istemli hareket üretme kapasitesini ciddi biçimde sınırlandırabilmektedir. Bu tür durumlarda beyin-bilgisayar arayüzleri, merkezi sinir sisteminden elde edilen sinyalleri anlamlandırarak dış cihazların doğrudan kontrolüne olanak tanıyan yardımcı bir teknoloji olarak öne çıkmaktadır. Klinik açıdan bakıldığında bu yaklaşım, iletişim kurma, temel çevresel kontrol sağlama ve yardımcı cihazları yönlendirme gibi kritik işlevlerde önemli bir potansiyel taşımaktadır.

EEG, non-invaziv yapısı, görece düşük maliyeti ve yüksek zamansal çözünürlüğü nedeniyle BCI çalışmalarında en yaygın kullanılan ölçüm yöntemlerinden biridir. Motor imgelem paradigmasında katılımcı gerçek bir hareket üretmeden belirli bir eylemi zihinsel olarak canlandırır. Bu sırada özellikle sensörimotor kortekste olay ilişkili desenkronizasyon ve senkronizasyon örüntüleri ortaya çıkar. Sol ve sağ el imgelemi sırasında gözlenen lateralize aktivite farklılıkları, bu iki görevin sınıflandırılmasını mümkün kılar.

Son yıllarda EEG sinyallerinin çözümlemesinde derin öğrenme temelli yöntemlerin kullanımı artmıştır. Özellikle konvolüsyonel sinir ağları, el ile özellik çıkarımı gereksinimini azaltarak ham ya da sınırlı ölçüde işlenmiş EEG verilerinden doğrudan temsil öğrenebilmektedir. Bununla birlikte EEG verilerinin düşük sinyal-gürültü oranı, kişiye özgü değişkenlik göstermesi ve çoğu veri kümesinde örnek sayısının sınırlı olması, model seçimini kritik hale getirmektedir.

Bu çalışmada PhysioNet EEG Motor Movement/Imagery Database kullanılarak 40 sağlıklı denekten elde edilen motor imgelem ve gerçek hareket koşulları birlikte değerlendirilmiştir. Amaç, üç farklı CNN mimarisinin performansını karşılaştırmak, küçük veri düzeninde hangi modelin daha kararlı sonuç verdiğini incelemek ve öğrenilen gömleme uzaylarının PCA ile ne ölçüde sıkıştırılabildiğini göstermektir.

2 Materyal ve Metotlar

2.1 Veri Seti

Çalışmada PhysioNet açık erişim platformunda yer alan EEG Motor Movement/Imagery Database kullanılmıştır. Bu veri tabanı, sağlıklı gönüllülerden BCI2000 sistemi aracılığıyla kaydedilmiş çok kanallı EEG oturumlarını içermektedir. Kayıtlar 160 Hz örnekleme frekansında ve 64 EEG kanalından toplanmıştır. Veri kümesinde dinlenme, gerçek hareket ve motor imgelem koşulları farklı koşullar halinde sunulmaktadır.

Bu çalışma kapsamında sol ve sağ el görevleriyle ilişkili R03, R07 ve R11 gerçek hareket koşulları ile R04, R08 ve R12 motor imgelem koşulları birlikte kullanılmıştır. Her iki görev kümesinde de T1 etiketi sol el, T2 etiketi sağ el görevine karşılık geldiği için etiket yapısı korunarak ortak bir sınıflandırma problemi oluşturulmuştur. İncelenen alt kümede her denek için yaklaşık 90 epoch elde edilmiştir. Bu düzen, hem örnek sayısını artırmış hem de benzer motor korteks örüntülerini ortak bir görev uzayında değerlendirmeye olanak tanımıştır.

2.2 Ön İşleme

Ham EEG sinyalleri doğrudan modele verilmeden önce temel bir ön işleme hattından geçirilmiştir. İlk aşamada 0.5–40 Hz bant geçiren filtre uygulanarak düşük frekanslı sürüklenmeler ile yüksek frekanslı gürültü bileşenleri bastırılmıştır. Ardından 60 Hz çentik filtresi kullanılarak şebeke kaynaklı parazit azaltılmıştır. Bu adımlar, özellikle motor imgelem analizinde önemli olan mu ve beta bantlarındaki bilginin korunmasına yardımcı olmuştur.

Olay işaretlerine dayalı epoch kesme aşamasında her deneme için 1.0–4.0 saniye aralığı seçilmiştir. İlk saniyenin dışarıda bırakılmasının temel gerekçesi, görev başlangıcı ile ilişkili geçici tepki bileşenlerini ve dikkat yönelim etkilerini azaltmaktır. Böylece analiz penceresi, daha çok saf motor imgelem dönemini temsil edecek biçimde tanımlanmıştır.

Son aşamada her kanal için z-normalizasyon uygulanmıştır. Ortalama ve standart sapma değerleri yalnızca eğitim katı üzerinden hesaplanmış, aynı dönüşüm test verisine taşınmıştır. Bu tercih, veri sızıntısını önlemek ve çapraz doğrulama sonuçlarının daha güvenilir olmasını sağlamak açısından önemlidir. Ön işleme sonunda her epoch, 64 kanal ve 481 zaman noktasından oluşan bir tensör olarak CNN modellerine verilmiştir.

2.3 Derin Öğrenme Modelleri

Bu çalışmada EEG tabanlı sınıflandırmada yaygın olarak kullanılan üç farklı konvolüsyonel mimari değerlendirilmiştir: EEGNet, ShallowConvNet ve DeepConvNet. EEGNet, depthwise ve separable convolution yapılarını kullanan kompakt bir ağıdır. Özellikle sınırlı veri senaryoları için geliştirilmiş olması nedeniyle EEG çalışmalarında sık başvurulan bir referans modeldir. Parametre sayısının düşük olması, aşırı öğrenme riskini azaltan önemli bir avantaj sunmaktadır.

ShallowConvNet daha yüzeysel bir mimari olup zamansal ve uzamsal konvolüsyon katmanlarını ardışık kullanır. Bu yapı, klasik ortak uzamsal örüntü ve bant gücü tabanlı yaklaşımlara yakın bir temsil öğrenme eğilimindedir. DeepConvNet ise daha fazla sayıda katman ve daha yüksek parametre kapasitesiyle daha karmaşık uzamsal-zamansal örüntüleri modellemeyi hedeflemektedir. Ancak bu esneklik, küçük veri kümelerinde genelleme açısından her zaman avantaj sağlamayabilir.

Tablo 1: Kullanılan CNN modellerinin temel özellikleri

Model	Parametre sayısı	Gömlene boyutu	Mimari özellik
EEGNet	6,450	240	Depthwise + Separable Conv
ShallowConvNet	105,562	1,040	Temporal + Spatial Conv
DeepConvNet	305,102	800	Çok katmanlı derin yapı

2.4 Model Eğitimi ve Değerlendirme

Tüm modeller aynı eğitim düzeninde karşılaştırılmıştır. Eğitim sürecinde Adam eniyileyicisi, çapraz entropi kaybı, 10^{-3} öğrenme hızı, 10^{-4} weight decay, en fazla 80 epoch ve erken durdurma yaklaşımı kullanılmıştır. Batch boyutu 16 olarak belirlenmiştir. Öğrenme hızı planlamasında cosine annealing yaklaşımı tercih edilmiştir.

Performans değerlendirmesi denek içi beş katlı çapraz doğrulama ile yürütülmüştür. Bu yaklaşım, aynı bireyin verilerinin eğitim ve test katlarında sistematik biçimde ayrılmasını sağlayarak kişi içi genellenabilirliği ölçmektedir. EEG verilerinin kişiye özgü doğası düşünüldüğünde, bu değerlendirme düzeni özellikle motor imgelem çalışmaları için anlamlıdır. Her fold içinde normalizasyon ve model eğitimi yalnızca eğitim verisi üzerinde gerçekleştirilmiş, test verisine sadece öğrenilen dönüşümler uygulanmıştır.

2.5 Boyut Azaltma

Derin modellerden elde edilen son katman öncesi gömlene vektörleri ayrıca PCA ile incelenmiştir. Amaç, öğrenilen temsillerin ne kadar sıkıştırılabildiğini ve bu temsillerin doğrusal ayrılabilirlik düzeyini değerlendirmektir. PCA sonrasında toplam varyansın yaklaşık %95'ini koruyan bileşenler seçilmiş ve bu uzayda lojistik regresyon sınıflandırıcısı uygulanmıştır.

3 Bulgular

Denek içi beş katlı çapraz doğrulama sonuçlarına göre en yüksek ortalama doğruluk EEGNet ile elde edilmiştir. EEGNet yaklaşık %72.5 ortalama doğruluk sergilerken, ShallowConvNet ve DeepConvNet modelleri %64–65 bandında kalmıştır. Bu bulgu, parametre sayısı düşük ve daha kompakt yapıda olan bir ağı, sınırlı örnekli EEG senaryolarında daha dengeli bir çözüm sunabileceğini göstermektedir.

EEGNet'in daha iyi performans göstermesinde birkaç etken rol oynamaktadır. İlk olarak, denek başına yaklaşık 90 epoch bulunması, yüksek parametreliliğin ağırların tam kapasiteyle öğrenmesini zorlaştırmaktadır. İkinci olarak, EEGNet'in mimarisi EEG verilerindeki uzamsal ve zamansal örüntülere özel olarak tasarlandığı için küçük veri kümelerinde daha verimli temsil öğrenebilmektedir. Buna karşılık DeepConvNet'in yüksek parametre kapasitesi, daha fazla esneklik sağlasa da mevcut veri miktarında aşırı uyum riskini artırmaktadır.

Tablo 2: Modellerin sınıflandırma performansı ve PCA sonrası durumları

Model	Temel doğruluk	PCA sonrası doğruluk	Yaklaşık düşüş
EEGNet	0.7250	0.6396	0.0855
ShallowConvNet	0.6469	0.5469	0.1000
DeepConvNet	0.6517	0.5558	0.0959

Gömlene vektörlerine uygulanan PCA sonuçları, tüm modellerde belirgin boyut azaltımının mümkün olduğunu göstermiştir. EEGNet için 240 boyutlu temsil 34 bileşene indirgenmiş ve bu işlem yaklaşık %86 oranında sıkıştırma sağlamıştır. ShallowConvNet ve DeepConvNet için sırasıyla yaklaşık 52 ve 40 bileşenli temsiller elde edilmiş, her iki modelde de yaklaşık %95 düzeyinde boyut azaltma başarılmıştır.

Bununla birlikte PCA sonrası lojistik regresyon ile yapılan sınıflandırmada tüm modellerde performans düşüşü görülmüştür. Bu durum, en yüksek varyansa sahip bileşenlerin her zaman sınıf ayrımı açısından en bilgilendirici eksenler olmadığını düşündürmektedir. Bir başka ifadeyle, derin ağların öğrendiği temsil uzayı doğrusal sınıflandırıcılar için doğrudan optimize edilmemiş olabilir. Yine de EEGNet gömlemelerindeki görece düşük kayıp, bu modelin daha kompakt ve daha tutarlı temsiller ürettiğine işaret etmektedir.

4 Tartışma

Elde edilen bulgular, EEGNet'in bu veri düzeninde ShallowConvNet ve DeepConvNet'e göre daha uygun bir denge sağladığını ortaya koymaktadır. Çalışmadaki veri miktarı göz önüne alındığında, daha küçük parametrelili bir mimarinin genelleme başarısının daha yüksek olması beklenen bir sonuçtur. Literatürde de EEGNet'in benzer veri kümelerinde güçlü bir başlangıç modeli olduğu sıkça vurgulanmaktadır.

PCA sonrası tüm modellerde doğruluk kaybı yaşanması, derin temsil uzaylarının yalnızca varyans esaslı doğrusal indirgeme ile tam olarak korunamadığını göstermektedir. Özellikle sınıf ayrımı için kritik olan ancak toplam varyansa daha az katkıda bulunan özellikler PCA sırasında geri planda kalmış olabilir. Ayrıca fold başına sınırlı test örneği bulunması da doğrusal sınıflandırıcının kararlılığını etkilemiş olabilir.

Çalışmanın bir diğer önemli yönü, kişi içi değerlendirme düzeninin tercih edilmiş olmasıdır. Bu yaklaşım, klinik kullanım senaryolarında bireysel kalibrasyonun önemini desteklemektedir. Nitekim motor imgelem performansının bireyler arasında ciddi farklılık gösterebildiği bilinmektedir. Bazı bireylerde belirgin ERD/ERS örüntüleri kolaylıkla ayrıştırılabilirken, bazı bireylerde aynı görevlerin sınıflandırılması daha güç hale gelmektedir.

Klinik açıdan değerlendirildiğinde, yaklaşık %72.5 doğruluk düzeyi tek başına tam bir kontrol sistemi için yeterli görülmeyebilir; ancak bireye özgü kalibrasyon, çevrim içi geri bildirim ve hata düzeltme mekanizmaları ile birleştirildiğinde pratik kullanım potansiyeli taşımaktadır. Özellikle yardımcı cihaz kontrolünde ikili komut yapıları için bu doğruluk düzeyi başlangıç düzeyinde anlamlı bir temel sunabilir.

5 Sonuç

Bu çalışmada PhysioNet EEG Motor Movement/Imagery Database kullanılarak sol ve sağ el motor imgelem görevlerinin derin öğrenme temelli sınıflandırılması incelenmiştir. EEGNet, ShallowConvNet ve DeepConvNet mimarileri karşılaştırılmış; denek içi beş katlı çapraz doğrulama sonuçlarına göre en iyi performans EEGNet ile elde edilmiştir. Ayrıca modellerin gömlene vektörleri PCA ile sıkıştırılmış, ancak bu indirgeme sonrasında doğrulukta belirgin düşüş gözlenmiştir.

Genel olarak sonuçlar, sınırlı örnekli EEG problemlerinde kompakt ağ mimarilerinin daha avantajlı olabileceğini göstermektedir. Gelecekte denekler arası değerlendirme düzenleri, veri artırma stratejileri, dikkat mekanizmaları ve hibrit derin öğrenme yaklaşımlarıyla bu performansın daha da geliştirilebileceği düşünülmektedir.

Kaynaklar

- [1] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer ve J. R. Wolpaw, “BCI2000: A General-Purpose Brain-Computer Interface (BCI) System,” *IEEE Transactions on Biomedical Engineering*, cilt 51, sayı 6, ss. 1034–1043, 2004.
- [2] A. L. Goldberger vd., “PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals,” *Circulation*, cilt 101, sayı 23, ss. e215–e220, 2000.
- [3] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung ve B. J. Lance, “EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces,” *Journal of Neural Engineering*, cilt 15, sayı 5, 056013, 2018.
- [4] R. T. Schirrmeister vd., “Deep learning with convolutional neural networks for EEG decoding and visualization,” *Human Brain Mapping*, cilt 38, sayı 11, ss. 5391–5420, 2017.
- [5] G. Pfurtscheller ve C. Neuper, “Motor imagery and direct brain-computer communication,” *Proceedings of the IEEE*, cilt 89, sayı 7, ss. 1123–1134, 2001.
- [6] B. Blankertz, R. Tomioka, S. Lemm, M. Kawanabe ve K.-R. Muller, “Optimizing spatial filters for robust EEG single-trial analysis,” *IEEE Signal Processing Magazine*, cilt 25, sayı 1, ss. 41–56, 2008.